


Web Crawler Project

목차

1. 웹사이트 크롤링 코드 분석 및 개선사항 제안
2. 크롤링 시나리오 및 코드 설명
3. 크롤링 코드 시연

크롤링 코드 요약

- 행동 단위로 시나리오 구성
- Selenium을 통해 브라우저를 자동화 하여 실제 사용자 행동을 재현(검색, 스크롤, 클릭 등)
- tshark 실행하여 네트워크 트래픽 데이터 수집
- Pcap파일 압축 후 서버에 업로드



상세 분석

bash_file : 환경 세팅, 스크립트 실행

google / naver : 사용자 행동 시나리오 정의

Ex) google_map.py : 지도 검색, 이동, 확대하는 시나리오

common : 크롤링 및 트래픽 수집 실행 엔진


이곳에서 서비스 스크립트 실행, 트래픽 캡처, 저장, 전송 담당 (Selenium 실행, tshark로 수집, 반복 실행)

utils : 광고 스킵, 키보드 이동 등 행동에 디테일을 더하기

dataset : 검색 키워드, 문장, 제외 도메인, 지도 위치 등을 모아두어 행동을 다양화시키는 데이터셋

exception : Step 실패 처리

connect_db : 상태 관리 및 로그 기록



실행 흐름

main.py

└ run_script.sh

└ google / naver 서비스 스크립트 실행

└ common 실행 엔진 (runner_utils.runner())

└ selenium (브라우저 자동화)

└ tshark (트래픽 캡처)

└ utils (행동 디테일) + dataset (랜덤성 데이터)

└ 종료 후 업로드 (upload_utils)

개선 사항 제안

1. 시나리오 단계별 실패 처리 개선

현재는 한 단계 실패 시 중단하고 패킷 버리는 형태 -> 중요 단계와 덜 중요한 단계를 구분하여 일부 실패 건너뛰고 진행 -> 수집 안정성 향상?

2. 브라우저 설정 다양화

화면 크기나 사용자 정보 등을 다양화 하여 봇 탐지/차단 위험 벗어나기

크롤링 시나리오

사이트는 야후 스포츠로 선정

1. 스포츠 페이지 접속
2. MLB, NBA 등 스포츠 랜덤 선택하여 클릭
3. 뉴스 카테고리 선택
4. 스크롤 후 뉴스 기사 선택
5. 기사 본문 스크롤

Yahoo sports 접속 및 스포츠 종목 랜덤 선택

← → ↻ sports.yahoo.com

yahoo/sports Search News Finance Sports More ▾ Mail Sign in

NFL Fantasy NCAA F NBA NHL NCAA B NCAA W MLB WNBA Betting B Boardroom Combat Soccer ... Fantasy ▾ Watch ▾ Network ▾

TRENDING LOCAL **FEATURED**

DATE	TIME	SPORT	SCORE	STATUS
TUE, 10:15 AM GMT+9	ESPN	SF	10-4	8-6
TUE, 12:00 PM GMT+9	NBCS	ORL	16-12	14-15
FINAL		NE	28	24
FINAL		PIT	29	24
FINAL		JAX	34	20
FINAL		BUF	23	20
FINAL		TB		

JETBRAINS IDEs
IntelliJ IDEA

For **productive**
Spring
development

TOP NEWS



PIT 29 DET 24 / FINAL

Aaron Rodgers is past his prime and the Steelers are far from great. Mike Tomlin wins anyway

With an exhilarating (and controversial) victory in

NFL

NFL playoff picture: Patriots, Bears, 49ers clinch postseason spots

NFL

Steelers WR DK Metcalf swings at Lions fan's head during sideline altercation

MLB

뉴스 카테고리 선택

← → ↺ sports.yahoo.com/mlb/ 📄 🖨️ ☆ ⬇️ 🌐

yahoo/sports

Search



News

Finance

Sports

More ▾

✉ Mail

Sign in

MLB ▾

News

Scores/Schedule

World Series

Postseason Bracket

MLB 50 Free Agents

Standings

Stats

Teams

Players ...

🏆 Fantasy ▾

📺 Watch ▾

🌐 Network ▾

2/21, 3:05 AM GMT+9



NY Yankees



BAL

2/21, 5:05 AM GMT+9



KC



TEX

2/21, 5:05 AM GMT+9



CWS



CHC

2/21, 5:10 AM GMT+9



SD



SEA

2/21, 5:10 AM GMT+9



ARI



COL

View all >

TOP MLB NEWS



Is Munetaka Murakami's signing with White Sox a bargain at \$34M for 2 years?

While Murakami's signing was a surprise, he perfectly fits the White Sox's plan and provides instant power to the middle of their lineup.

Rays deal SP Shane Baz to Orioles as part of 5-player trade

Sean Leahy

Tyler Skaggs wrongful death trial ends as family reaches settlement with Angels

Sean Leahy

John Means ruptures Achilles on same day he

뉴스 목록 스크롤 후 뉴스 선택

← → ↺

sports.yahoo.com/mlb/news/

📄 🖨️ ☆ 📌

yahoo/sports

Search

Q

News Finance Sports More ▾

Mail

Sign in

MLB News



Red Sox reportedly land Willson Contreras in trade with Cardinals

The Red Sox are sending right-hander Hunter Dobbins and several minor-league players to St. Louis in the deal.

Yahoo Sports · 13h ago



MLB free agency 2025-26: Top 50 players available this winter, starting with Kyle Tucker and Alex Bregman

This free-agent class is headlined by power hitters who would amplify any team's lineup.

Yahoo Sports · 18h ago



Is Munetaka Murakami a bargain at \$34M for 2 years? His surprise signing with White Sox fits nicely in Chicago's rebuild

Murakami is the type of gamble a team like the White Sox can and should make. The Sox were able to be opportunistic after Murakami's market came back to them.

Yahoo Sports · 19h ago



Japanese star Munetaka Murakami agrees to 2-year, \$34M deal with White Sox

The latest Japanese star to enter MLB has found his team.

Yahoo Sports · 20h ago



Dodgers officially run up \$169 million luxury tax bill for 2025, larger than payrolls of 12 teams

The final tally for the Dodgers' 2025 payroll: \$417.3 million.

Yahoo Sports · 2d ago



포토샵, 프리미어 프로까지
20개 이상의 앱
Creative Cloud
구매하기

TRENDING

 Playoff Picture

 White Sox get Murakami

 Chiefs lose another QB

 CFP quarterfinal matchups

 Paul has surgery after loss

 Thunder wins tracker

 QBs in transfer portal

 NBA trade rumors

 2026 Draft Order

뉴스 본문 스크롤

← → ↺ sports.yahoo.com/mlb/article/is-munetaka-murakami-a-bargain-at-34m-for-2-years-his-surprise-signing-with-white-sox-fits-nicely-in-chicagos-rebuild-191334685.html ↻ 📄 ☆ ⬇️ 인우 ⋮

yahoo/sports

Search



News

Finance

Sports

More ▾

Mail

Sign in

IS Munetaka Murakami a bargain at \$34M for 2 years? HIS surprise signing with White Sox fits nicely in Chicago's rebuild

Murakami represents the type of gamble a team like the White Sox can and should make

Story by **yahoo/sports**



Munetaka Murakami, 25, hit 265 career home runs in the NPB. (Sam Navarro-USA TODAY Sports) (USA TODAY Sports / Reuters)



Russell Dorsey · National MLB Insider

Mon, December 22, 2025 at 4:13 AM GMT+9 · 4 min read



8

TOP MLB HEADLINES

Rays deal SP Shane Bieber to Orioles as part of 5-player trade

Tyler Skaggs wrongful death trial ends as family reaches settlement with Angels

John Means ruptures Achilles on same day he was to sign with a team

Padres bring back Michael King on reported 3-year, \$75M deal with 2 opt-outs



Ads by Google

Stop seeing this ad

Why this ad? ⓘ

import

```
import random
import time
from selenium import webdriver # Selenium 웹드라이버 핵심 모듈
from selenium.webdriver.common.by import By # HTML 요소를 찾을 때 사용하는 선택자 타입
from selenium.webdriver.support.ui import WebDriverWait # 특정 요소가 나타날 때까지 기다리기 위한 도구
from selenium.webdriver.support import expected_conditions as EC # 요소 클릭 가능, 존재 여부 등 대기 조건 정의
from selenium.webdriver.chrome.service import Service
from selenium.webdriver.chrome.options import Options
from webdriver_manager.chrome import ChromeDriverManager # ChromeDriver를 자동으로 설치 및 관리하기 위한 라이브러리
from selenium.common.exceptions import TimeoutException #예외 처리용
```

Selenium 기반 크롤링에 필요한 핵심 모듈만 사용

WebDriverWait + EC를 통해 안정성 고려 (크롤러에서 권장되는 방식이라고 한다)

웹드라이버 생성

```
# Driver 생성 및 기본 옵션 설정
def create_driver():
    options = Options()
    options.add_argument("--start-maximized") # 사용자 행동처럼 보이도록 브라우저를 최대화된 상태로 실행
    options.add_argument("--disable-blink-features=AutomationControlled") # Selenium 자동화 탐지 우회
    options.page_load_strategy = "eager" #속도 향상

    # ChromeDriver 자동 관리
    driver = webdriver.Chrome(
        service=Service(ChromeDriverManager().install()),
        options=options
    )
    return driver
```

브라우저 자동화 탐지를 최소화하고 실제 사용자 환경과 유사하게 Chrome WebDriver를 생성하는 함수

사람처럼 행동하는 크롬 브라우저를 띄워 실행하는 역할

Yahoo Sports 접속

```
# 1. Yahoo Sports 접속
def open_yahoosports_main(driver):
    print("1. Yahoo Sports 접속")
    driver.get("https://sports.yahoo.com/") # Yahoo Sports 메인 페이지 이동
    time.sleep(2) #페이지 로딩 대기
```

Yahoo Sports 메인 페이지 접속, 이후 행동을 위해 최소한의 로딩 시간 확보

랜덤으로 종목 선택

```
# 2. 스포츠 종목 랜덤 선택
def click_category(driver):
    print("2. 스포츠 종목 랜덤 선택")
    sports = (
        "https://sports.yahoo.com/nfl/",
        "https://sports.yahoo.com/ncaaf/",
        "https://sports.yahoo.com/nba/",
        "https://sports.yahoo.com/ncaab/",
        "https://sports.yahoo.com/ncaaw/",
        "https://sports.yahoo.com/mlb/",
        "https://sports.yahoo.com/wnba/"
    ) # 주요 스포츠 종목 URL 목록

    driver.get(random.choice(sports)) # 하나 랜덤으로 선택하여 이동
    time.sleep(3)
```

실제 사용자가 다양한 스포츠 종목 탐색하는 상황을 재현하도록
랜덤으로 종목 선택 후 이동하게 했다.

(news탭 없는 종목 제외)

News 탭 클릭

```
# 3. 종목 News 탭 클릭
def click_news_tab(driver):
    print("3. 종목 News 탭 클릭 시도")
    wait = WebDriverWait(driver, 3)    # 최대 3초까지 요소 대기

    try:
        # News 텍스트를 가진 탭 요소를 찾아 클릭 가능 상태가 될 때까지 대기
        newstab= wait.until(
            EC.element_to_be_clickable(
                (By.XPATH, "//span[normalize-space()='News']/ancestor::a") #xpath는 ui 변경에 강함
            )
        )
        newstab.click() # News 탭 클릭
        time.sleep(3) #로딩 대기

    except TimeoutException: #news 탭 없을 때 종료하도록
        print("News 탭을 찾을 수 없음.")
```

선택한 스포츠 종목 페이지에서 뉴스 목록으로 이동

뉴스 목록 스크롤

```
# 4. 스크롤하며 기사 URL 수집
def scroll_news_page(driver):
    print("4. 기사 목록 스크롤 및 기사 URL 수집")
    c = set() # 중복 제거를 위한 집합

    for _ in range(3): # 페이지 스크롤
        driver.execute_script("window.scrollTo(0, 1000);")
        time.sleep(1.5)

        #뉴스 기사만 잡아내기 위해 여러가지 조건 걸었다
        urls = driver.execute_script("""
            const links = [];
            document.querySelectorAll('a').forEach(a => {
                const href = a.href || '';
                if (
                    href.includes('sports.yahoo.com') &&
                    (href.includes('/article/') &&
                     !href.includes('/watch/') &&
                     !href.includes('/fantasy/'))
                ) {
                    links.push(href);
                }
            });
            return links;
        """)
        for u in urls:
            c.add(u) # 중복 제거하고 저장
    return list(c)
```

스크롤을 발생시키고
DOM에서 기사로
보이는 링크를 모은다.

뉴스 클릭

```
# 5. 기사 클릭
def click_news(driver, article_urls):
    if not article_urls:
        return False

    article_url = random.choice(article_urls) #수집한 후보중 하나 랜덤 방문
    print("5. 기사 랜덤 선택 및 본문 이동")

    driver.get(article_url)
    time.sleep(3)
    return True
```

뉴스 후보 중 하나를 랜덤으로 선택해 뉴스 본문 페이지 진입

뉴스 본문 스크롤

```
# 6. 기사 본문 스크롤
def read_post_with_scroll(driver):
    print("6. 기사 본문 스크롤")
    for _ in range(8):
        driver.execute_script([
            f"window.scrollTo(0, 400);" # 한 번에 400px씩 아래로 이동
        ])
        time.sleep(0.8)
    print("기사 읽기 완료")
```

작은 단위로 반복 스크롤하여 기사 읽는 행동 재현